


딥페이크 히트맵 분석 보고서

1. 분석 개요

- 모델명: MobileNetV3-Small
- 모델 유형: 한국인 전용 모델
- 분석 일시: 2025-11-10 00:21:13
- 예측 결과: Fake (78.79%)
- 딥페이크 확률: 34.00%

2. Grad-CAM 시각화



3. LangChain 기반 AI 해석

Grad-CAM (Gradient-weighted Class Activation Mapping) 히트맵은 딥러닝 모델이 특정 이미지의 어떤 부분에 주목했는지를 시각적으로 나타내주는 도구입니다. 제공된 정보에서 아래와 같이 Grad-CAM 해석을 수행할 수 있습니다.

해석

1. **붉은색 영역의 의미**:

- **합성 흔적**: 붉은색 영역이 얼굴의 경계, 눈 주위, 입가와 같은 부분에 집중되어 있다면, 이는 인물의 원래 이미지와 합성 이미지의 경계가 부자연스럽게 처리된 부분을 나타낼 수 있습니다. 이러한 경계는 종종 부드러운 피부 질감으로 인해 눈에 띄지 않을 수 있지만, 깊이감이나 음영 처리에서의 비일관성으로 인해 인식될 수 있습니다.

- **피부 질감**: 딥페이크 기술들은 종종 합성된 이미지에서 질감의 일관성을 유지하기 어려워하는 경향이 있습니다. 붉은색 영역이 피부의 표면, 특히 주름이나 모공이 있는 부분에 잘 나타난다면 인공적으로 생성된 피부 질감이 비자연적일 수 있다는 것을 의미합니다. 예를 들어, 눈 주위나 입가에서만 비정상적인 매끄러움이나 지나치게 고른 질감을 나타낼 경우, 이는 합성된 이미지의 주요 신호로 작용할 수 있습니다.

- **조명 왜곡**: 딥페이크 이미지에서는 종종 조명의 방향이나 밝기가 비논리적으로 왜곡될 수 있습니다. 붉은색 영역이 조명 효과가 달라진 부분에 나타난다면, 이는 인물의 자연스러운 조명과 어색하게 어울리지 않기 때문에 인식될 수 있습니다. 예를 들어, 얼굴 한쪽이 비정상적으로 밝거나 그림자 효과가 인공적으로 조작된 경우를 들 수 있습니다.

신뢰도 및 한계점

- **신뢰도**: 모델은 78.79%의 확률로 'Fake'로 분류했으며, 이는 상당히 높은 신뢰도로 볼 수 있습니다. Grad-CAM 히트맵이 특정하고 명확한 시각적 증거를 나타내고 있다면, 이 결과의 신뢰성이 더욱 증가합니다. 그러나 일반적으로, 이러한 모델이 특정 표정이나 각도에서 잘못된 판단을 내릴 가능성도 존재하기 때문에, 추가적인 검증이 필요합니다.

- **한계점**: Grad-CAM이 제공하는 히트맵은 모델이 주장하는 증거를 시각적으로 해석할 수 있도록 돋지만, 여전히 두 가지 큰 한계가 있습니다.

1. **과잉 해석의 가능성**: 모델이 로우 레벨의 특징 (예: 색상, 패턴)만을 바탕으로 예측할 때, 그 결과는 과히 실질적으로 해석되지 않을 수 있으며, 간혹 실제 비딥 페이크 이미지에서 나타날 수 있는 자연스러운 변화를 잘못 감지할 위험이 있습니다.

2. **데이터 편향**: 모델 학습 데이터를 기반으로 판단을 하기에, 일부 이미지 유형에서 편향된 결과를 제공할 수 있습니다. 특정 조건에서 잘못된 예측이 발생할 수 있는 여지가 높습니다.

추가적인 심층 결과

- **시각적 특성 검증**: Grad-CAM 히트맵을 활용하여 이미지의 각 부분이 진짜와 가짜의 구별에 기여하는 시각적 특성을 검증할 수 있습니다. 예를 들어, 얼굴의 비대칭성, 특정 감정의 시각적 표현이 어떻게 다르게 나타나는지를 비교함으로써 더욱 깊이 있는 분석을 할 수 있습니다.

- **단계적 분석 접근법**: 딥페이크 탐지 모델의 성능 평가 시, Grad-CAM의 히트맵을 활용한 단계적 분석이 중요합니다. 모델이 주목하는 부분과 그 결과가 어떻게 관련되는지를 명확하게 이해함으로써, 모델의 신뢰성을 높이는 데 기여할 수 있습니다.

이러한 방식으로 Grad-CAM 해석을 통한 딥페이크 탐지는 이제 단순한 이미지 분류를 넘어서 보다 정교한 시각적 분석으로 나아갈 수 있습니다.

4□. 결론 및 권장 조치

본 분석은 Grad-CAM 시각 주목도를 중심으로 진행되었습니다.

AI의 결과는 참고용으로 사용해야 하며, 법적 판단이나 공식 증거로 사용되지 않습니다.

결과의 신뢰도를 높이기 위해 다양한 이미지 소스로 교차 검증을 권장합니다.