

딥페이크 히트맵 분석 보고서

1. 분석 개요

- 모델명: MobileNetV3-Small
- 모델 유형: 외국인 전용 모델
- 분석 일시: 2025-11-07 09:00:23
- 예측 결과: Fake (52.49%)
- 딥페이크 확률: 18.80%

2. Grad-CAM 시각화



3. LangChain 기반 AI 해석

Grad-CAM(Gradient-weighted Class Activation Mapping) 히트맵은 딥러닝 모델이 특정 예측을 할 때, 어떤 시각적 특징이 결정적인 영향을 미쳤는지를 시각적으로 나타내는 기법입니다. 제공된 정보에 따라 Grad-CAM 히트맵을 분석해 보겠습니다.

Grad-CAM 해석

1. **붉은색 영역의 중요성**:

붉은색 영역은 모델이 딥페이크 여부를 판단하기 위해 중점을 두었던 부분으로, 주로 두 가지 요소에서 시각적 특징을 찾았을 가능성이 큼니다:

- **합성 흔적**: 이미지에서 불연속적인 경계, 고립된 부분 등 자연스럽지 않은 특징이 있는 경우 모델은

이 부분에 높은 중요도를 부여했을 수 있습니다.

- ****피부 질감 불일치****: 자연 피부 질감은 통상적인 조명 및 환경에 따라 불균일하게 분포되어 있습니다. 딥페이크 이미지에서는 인위적인 필터링이 적용될 수 있으며, 이것이 피부 질감에서의 불규칙성을 만들어 낼 수 있습니다. 이에 따라, 모델은 피부 질감의 비정상적인 균질함이나 지나치게 매끄러운 표면을 감지했을 수도 있습니다.

2. ****조명 왜곡****:

조명이 인위적으로 처리가 되었거나, 이미지의 소스가 서로 다른 조명 환경에서 촬영된 경우, 인물의 그림자나 하이라이트가 비정상적으로 보일 수 있습니다. Grad-CAM의 붉은색 영역에서 이러한 조명 패턴의 왜곡이 강조되었다면, 이는 딥페이크의 징후로 작용할 수 있습니다. 조명과 그림자의 불일치나 공간적 배치 오류도 딥페이크 판별에 중요한 요소로 작용합니다.

신뢰도 및 한계점

- ****신뢰도****:

- Grad-CAM은 모델의 결정 과정을 시각적으로 표현하기 때문에, 특정 영역에서의 예측 기반 근거를 이해하는 데 큰 도움이 됩니다. 특히 언급된 붉은색 영역이 피부 질감과 조명에 집중되어 있다면, 이는 중요한 신호로 해석될 수 있습니다.

- 다만, 52.49%의 fake 확률은 다소 경계선에 위치한다는 점에서, 모델의 판단이 확신을 갖고 있지는 않음을 시사합니다.

- ****한계점****:

- Grad-CAM은 시각적으로 모델의 결정 근거를 제공하나, 최종 결과의 진정성을 보장하지는 않습니다. 즉, 특정 붉은 영역이 딥페이크를 강력하게 시사하더라도, 실제로 그 이미지가 진짜일 가능성 또한 존재합니다.

- 모델 훈련의 데이터셋에 따라 발생할 수 있는 일반화의 한계도 있습니다. 최신의 또는 매우 정교한 딥페이크 기술이 반영되지 않을 경우, Grad-CAM은 잘못된 판단 근거를 제공할 수 있습니다.

- 또한, 사람의 초점이 Gradient-weighted Class Activation Mapping에 지나치게 의존할 경우, 인간의 주관적인 판단이 왜곡될 수 있습니다.

심층 결과와 추가 설명

- ****이미지 불일치와 복잡성****: 높고 정교한 복합적 요소들(예: 감정 표현, 표정 변화 등)이 있는 경우, 모델이 모든 작용을 완벽히 캡처하지 못할 수 있습니다.

- ****데이터 세트 다양성****: 모델의 훈련 과정에서 적절한 다양성이 없다면, 예외적인 예에 대한 적합성 부족이 발생할 수 있습니다.

- ****인간의 판단****: 결론적으로, 모델의 결과와 함께 인간 전문가의 판단이 필요합니다. 이를 통해 이미지의 맥락이나 문화적 요소와 같은 미세한 사안을 고려할 수 있습니다. 전문가들은 이미지의 감정 표현, 움직임 등을 종합적으로 평가하여 보다 심도 있는 분석을 제공할 수 있습니다.

이와 같이 Grad-CAM 해석은 모델의 예측을 이해하는 데 도움이 되며, 분석의 신뢰성과 한계에 대한 깊은 성찰이 요구됩니다.

4. 결론 및 권장 조치

본 분석은 Grad-CAM 시각 주목도를 중심으로 진행되었습니다.

AI의 결과는 참고용으로 사용해야 하며, 법적 판단이나 공식 증거로 사용되지 않습니다.

결과의 신뢰도를 높이기 위해 다양한 이미지 소스로 교차 검증을 권장합니다.